

Statistika: 3 laboratorinis darbas

Junior Statistikai

Naudotos bibliotekos:

```
library(readxl)
library(dplyr)
library(tidyr)
library(e1071)
library(ggplot2)
```

1. Duomenų rinkinio aprašymas

```
duomenys <- read_excel("Duomenys.xlsx", sheet = "duomenys", range = "A1:U5001")

duomenys <- duomenys %>%
  mutate(across(c(1, 2, 5:15, 17:21), ~as.numeric(.))) %>%
  mutate(exam_score = na_if(exam_score, 1.0)) %>%
  mutate(productivity_score = na_if(productivity_score, 1.0))
```

Šiame *duomenų rinkinyje* pateikiama informacija apie 5000 studentų ir jų mokymosi įpročius, gyvenimo būdą bei akademinius rezultatus.

Duomenų šaltinis – Kaggle platforma: <https://www.kaggle.com/datasets/samPATHvinayakbablu/ultimate-student-productivity-dataset?resource=download>

Pagrindiniai kintamieji

Demografiniai duomenys:

- student_id – unikalus studento identifikatorius
- age – amžius
- gender – lytis (Male, Female, Other)
- academic_level – studijų lygis

Mokymosi įpročiai:

- study_hours – bendras mokymosi laikas per dieną

- self_study_hours – savarankiško mokymosi laikas
- online_classes_hours – laikas praleistas online paskaitose

Laisvalaikis ir įpročiai:

- social_media_hours – laikas socialiniuose tinkluose
- gaming_hours – laikas žaidžiant žaidimus
- screen_time_hours – bendras laikas prie ekrano
- sleep_hours – miego trukmė

Gyvenimo būdas:

- exercise_minutes – fizinio aktyvumo trukmė (minutėmis)
- caffeine_intake_mg – kofeino suvartojimas (mg)
- part_time_job – ar studentas dirba (0/1)
- upcoming_deadline – ar turi artėjančių atsiskaitymų (0/1)
- internet_quality – interneto kokybė

Psichologiniai rodikliai:

- mental_health_score – psichinės sveikatos įvertinimas
- focus_index – susikaupimo indeksas
- burnout_level – perdegimo lygis

Rezultatai:

- productivity_score – produktyvumo įvertinimas
- exam_score – egzamino rezultatas


2. Turimų duomenų grafikai

```
# Histograma 1 - egzamino rezultatai (exam_score)
# Histograma 2 - produktyvumo lygis (productivity_score)
# Histograma 3 - perdegimo lygis (burnout_level)
# Histograma 4 - koncentracijos indeksas (focus_index)
duomenys %>%
  dplyr::select(exam_score, productivity_score, burnout_level, focus_index) %>%
  pivot_longer(cols = everything(),
               names_to = "kintamasis",
               values_to = "reiksme") %>%
  ggplot(aes(x = reiksme)) +
  geom_histogram(binwidth = 3, fill = "steelblue", color = "white") +
```

```

facet_wrap(~kintamasis, scales = "free",
  labeller = labeller(kintamasis = c(
    exam_score = "Egzamino rezultatas",
    productivity_score = "Produktyvumo lygis",
    burnout_level = "Perdegimo lygis",
    focus_index = "Koncentracijos indeksas"
  ))) +
labs(x = "Reikšmė", y = "Dažnis") +
theme_minimal()

```




```

# Sklaidos diagrama 1 - ryšys tarp mokymosi valandų ir egzamino rezultato
ggplot(duomenys, aes(x = study_hours, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp mokymosi valandų ir egzamino rezultato",
    x = "Mokymosi valandos",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()


```

Ryšys tarp mokymosi valandų ir egzamino rezultato




```
# Sklaidos diagrama 2 - ryšys tarp produktyvumo lygio ir egzamino rezultato
ggplot(duomenys, aes(x = productivity_score, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp produktyvumo lygio ir egzamino rezultato",
    x = "Produktyvumo lygis",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp produktyvumo lygio ir egzamino rezultato




```
# Sklaidos diagrama 3 - ryšys tarp perdegimo lygio ir egzamino rezultato
ggplot(duomenys, aes(x = burnout_level, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp perdegimo lygio ir egzamino rezultato",
    x = "Perdegimo lygis",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp perdegimo lygio ir egzamino rezultato



```
# Sklaidos diagrama 4 - ryšys tarp koncentracijos indekso ir egzamino rezultato
ggplot(duomenys, aes(x = focus_index, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp koncentracijos indekso ir egzamino rezultato",
    x = "Koncnetracijos indeksas",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp koncentracijos indekso ir egzamino rezultato




```
# Duomenų pertvarkymas grafikams
```


```
duomenys$part_time_job <- factor(duomenys$part_time_job,  
                                levels = c(0, 1),  
                                labels = c("Ne", "Taip"))  
duomenys$upcoming_deadline <- factor(duomenys$upcoming_deadline,  
                                     levels = c(0, 1),  
                                     labels = c("Ne", "Taip"))
```

```
# Boxplot 1 - perdegimo lygis pagal artėjančius atsiskaitymus
```

```
ggplot(duomenys, aes(x = upcoming_deadline, y = burnout_level, fill = upcoming_deadline)) +  
  geom_boxplot(alpha = 0.7) +  
  labs(  
    title = "Perdegimo lygis pagal artėjančius atsiskaitymus",  
    x = "Ar artėja atsiskaitymas",  
    y = "Perdegimo lygis",  
    fill = "Atsiskaitymas"  
  ) +  
  theme_minimal() +  
  scale_fill_brewer(palette = "Set2")
```



```
# Boxplot 2 - perdegimo lygis pagal tai ar studentas turi darbą
ggplot(duomenys, aes(x = part_time_job, y = burnout_level, fill = part_time_job)) +
  geom_boxplot(alpha = 0.7) +
  labs(
    title = "Perdegimo lygis pagal studento darbą",
    x = "Ar turi darbą?",
    y = "Perdegimo lygis",
    fill = "Darbas"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Set2")
```

3. Skaitinės charakteristikos

Analizuojant kiekybinius duomenų rinkinio kintamuosius, buvo apskaičiuotos pagrindinės statistinės charakteristikos: vidurkis, mediana, standartinis nuokrypis, minimali ir maksimali reikšmės, dispersija, kvartilai, Tarpkvartilinis plotis, asimetrijos korf. ir eksceso koef..

```
kiekybiniai <- c(2, 5:13, 17:21)
funkcijos <- list(
  Vidurkis = ~mean(.x, na.rm = TRUE),
  Min = ~min(.x, na.rm = TRUE),
  Max = ~max(.x, na.rm = TRUE),
  Dispersija = ~var(.x, na.rm = TRUE),
  StNuokrypis = ~sd(.x, na.rm = TRUE),
  Q1 = ~quantile(.x, 0.25, na.rm = TRUE),
  Q2 = ~median(.x, na.rm = TRUE),
  Q3 = ~quantile(.x, 0.75, na.rm = TRUE),
  IQR = ~IQR(.x, na.rm = TRUE),
  Asimetrija = ~skewness(.x, na.rm = TRUE),
  Eksecasas = ~kurtosis(.x, na.rm = TRUE)
)

ch <- duomenys %>%
  dplyr::select(all_of(c(2, 5:13, 17:21))) %>%
  summarise(across(everything(), funkcijos)) %>%
```

```

pivot_longer(everything(),
             names_to = c("Kintamasis", "Charakteristika"),
             names_sep = "_(?=[^_]+$)" %>%
pivot_wider(names_from = Charakteristika, values_from = value)

print(ch)

```

```

## # A tibble: 15 x 12
##   Kintamasis Vidurkis   Min   Max Dispersija StNuokrypis   Q1   Q2   Q3
##   <chr>         <dbl> <dbl> <dbl>    <dbl>    <dbl> <dbl> <dbl> <dbl>
## 1 age          20.5  16    25      8.24     2.87  18    20    23
## 2 study_hours   4.54  0    11.8    3.32     1.82  3.25  4.53  5.76
## 3 self_study~   2.48  0     7.41    1.39     1.18  1.66  2.48  3.29
## 4 online_cla~   2.01  0     6      0.968    0.984  1.32  2.01  2.69
## 5 social_med~   3.00  0     8.28    2.15     1.47  1.99  2.98  4.03
## 6 gaming_hou~   1.56  0     5.64    1.23     1.11  0.67  1.49  2.34
## 7 sleep_hours   7.02  4     10     1.35     1.16  6.24  7.01  7.81
## 8 screen_tim~   6.98  1    15.3    6.18     2.49  5.28  6.95  8.71
## 9 exercise_m~   74.5  0   149    1843.    42.9  37    75   112
## 10 caffeine_i~  251.  0   499   20691.   144.  129   252  376
## 11 mental_he~   5.51  1    10     8.23     2.87  3     5     8
## 12 focus_index  29.4  1   63.5   99.3     9.96  22.6  29.4  36.2
## 13 burnout_le~  45.6  1   97.6  203.     14.2  35.7  45.7  55.4
## 14 productivi~  37.8  1.04 98.0   269.     16.4  25.9  37.2  49.4
## 15 exam_score   20.6  1.01 64.1   127.     11.3  11.9  19.6  28.4
## # i 3 more variables: IQR <dbl>, Asimetrija <dbl>, Eksecesas <dbl>

```

4. Dažnių lentelės

Buvo sudarytos dažnių lentelės kategoriniams kintamiesiems

```

kategoriniai <- c(3:4, 14:16)

for (kol in kategoriniai) {
  pav <- colnames(duomenys)[kol]
  cat("\n", pav, "\n")

  lentele <- duomenys %>%
    count(.data[[pav]]) %>%
    rename(Kategorija = 1, Daznis = n) %>%
    mutate(Procentai = round(Daznis / sum(Daznis) * 100, 2))

  print(lentele)
}

```

```

##
## gender
## # A tibble: 3 x 3
##   Kategorija Daznis Procentai
##   <chr>      <int>    <dbl>
## 1 Female    1630    32.6

```

```
## 2 Male          1719      34.4
## 3 Other          1651      33.0
##
## academic_level
## # A tibble: 3 x 3
##   Kategorija    Daznis Procentai
##   <chr>        <int>    <dbl>
## 1 High School    1672      33.4
## 2 Postgraduate   1687      33.7
## 3 Undergraduate  1641      32.8
##
## part_time_job
## # A tibble: 2 x 3
##   Kategorija Daznis Procentai
##   <fct>      <int>    <dbl>
## 1 Ne        2509      50.2
## 2 Taip      2491      49.8
##
## upcoming_deadline
## # A tibble: 2 x 3
##   Kategorija Daznis Procentai
##   <fct>      <int>    <dbl>
## 1 Ne        2493      49.9
## 2 Taip      2507      50.1
##
## internet_quality
## # A tibble: 3 x 3
##   Kategorija Daznis Procentai
##   <chr>      <int>    <dbl>
## 1 Average    1638      32.8
## 2 Good       1722      34.4
## 3 Poor       1640      32.8
```

5. Hipotezės

Šiame laboratoriniame darbe tikrinamos 7 hipotezės. Dalis jų sudaryta pagal antro laboratorinio darbo hipotezes, tačiau vietoje parametrinių testų taikomi neparametriniai kriterijai ir chi kvadrato kriterijai. Hipotezės, kurioms netiko pateiktas testų sąrašas, pakeistos naujomis, kad būtų galima pritaikyti Kruskal-Wallis ir chi kvadrato nepriklausomumo kriterijus.

Reikšmingumo lygmuo visiems testams: $\alpha = 0,05$.

1. H1. Pakankamas miegas yra susijęs su aukštesniais egzamino rezultatais.

- H0: studentų, miegančių bent 7 valandas, ir studentų, miegančių mažiau nei 7 valandas, egzamino rezultatų pasiskirstymai nesiskiria.
- H1: studentų, miegančių bent 7 valandas, egzamino rezultatai yra aukštesni.

2. H2. Fiziškai aktyvių studentų koncentracijos indeksas skiriasi nuo bendro koncentracijos indekso lygio.

- H0: fiziškai aktyvių studentų koncentracijos indekso mediana lygi bendro koncentracijos indekso medianai.

- H1: fiziškai aktyvių studentų koncentracijos indekso mediana skiriasi nuo bendros medianos.

3. H3. Perdegimo lygis skiriasi pagal interneto kokybės grupes.

- H0: perdegimo lygio pasiskirstymas visose interneto kokybės grupėse yra vienodas.
- H1: bent vienoje interneto kokybės grupėje perdegimo lygio pasiskirstymas skiriasi.

4. H4. Studentai prie ekrano praleidžia daugiau laiko negu mokosi.

- H0: ekrano laiko ir mokymosi laiko medianų skirtumas lygus 0.
- H1: ekrano laiko mediana yra didesnė už mokymosi laiko medianą.

5. H5. Produktyvumo balas skiriasi pagal akademinį lygį.

- H0: produktyvumo balo pasiskirstymas visuose akademinuose lygiuose yra vienodas.
- H1: bent viename akademiniame lygyje produktyvumo balo pasiskirstymas skiriasi.

6. H6. Studentų, besimokančių daugiau nei 5 valandas per dieną, dalis yra lygi 50 %.

- H0: studentų, besimokančių daugiau nei 5 valandas per dieną, dalis lygi 0,5.
- H1: studentų, besimokančių daugiau nei 5 valandas per dieną, dalis nėra lygi 0,5.

7. H7. Artėjančio atsiskaitymo grupėse skiriasi aukšto produktyvumo pasiekimo proporcija.

- H0: aukšto produktyvumo proporcija nepriklauso nuo to, ar studentui artėja atsiskaitymas.
- H1: aukšto produktyvumo proporcija priklauso nuo artėjančio atsiskaitymo.

6. Testai

Hipotezėms tikrinti pasirinkti šie testai:

```
tests <- data.frame(
  Hipoteze = c("H1", "H2", "H3", "H4", "H5", "H6", "H7"),
  Testas = c(
    "Mann-Whitney-Wilcoxon rangų sumų testas",
    "Vienos imties Wilcoxon testas",
    "Kruskal-Wallis testas",
    "Porinis Wilcoxon testas",
    "Kruskal-Wallis testas",
    "Chi kvadrato suderinamumo kriterijus",
    "Chi kvadrato nepriklausomumo kriterijus"
  ),
  Kintamieji = c(
    "exam_score pagal sleep_group",
    "focus_index aktyvių studentų grupėje",
    "burnout_level pagal internet_quality",
    "screen_time_hours ir study_hours",
    "productivity_score pagal academic_level",
    "study_hours > 5",
    "upcoming_deadline ir high_productivity"
  )
)
tests
```

```
## Hipoteze
## 1 H1 Mann-Whitney-Wilcoxon rangų sumų testas
## 2 H2 Vienos imties Wilcoxon testas
## 3 H3 Kruskal-Wallis testas
## 4 H4 Porinis Wilcoxon testas
## 5 H5 Kruskal-Wallis testas
## 6 H6 Chi kvadrato suderinamumo kriterijus
## 7 H7 Chi kvadrato nepriklausomumo kriterijus
## Kintamieji
## 1 exam_score pagal sleep_group
## 2 focus_index aktyvių studentų grupėje
## 3 burnout_level pagal internet_quality
## 4 screen_time_hours ir study_hours
## 5 productivity_score pagal academic_level
## 6 study_hours > 5
## 7 upcoming_deadline ir high_productivity
```

7. Sąlygų tikrinimas

Pirmiausia paruošiami papildomi grupavimo kintamieji. Jeigu ankstesnėse darbo dalyse duomenų objektas vadintas `duomenys`, naudojamas jis; jeigu vadintas `data`, naudojamas `data`.

```
lab3_data <- if (exists("duomenys")) duomenys else data

lab3_data$sleep_group <- factor(
  ifelse(lab3_data$sleep_hours >= 7,
    "Miega >= 7 val.", "Miega < 7 val."),
  levels = c("Miega < 7 val.", "Miega >= 7 val.")
)

lab3_data$active_group <- factor(
  ifelse(lab3_data$exercise_minutes > 60,
    "Fiziškai aktyvūs", "Mažiau aktyvūs")
)

lab3_data$study_more_5 <- factor(
  ifelse(lab3_data$study_hours > 5, "Daugiau nei 5 val.", "Ne daugiau nei 5 val.")
)

lab3_data$high_productivity <- factor(
  ifelse(lab3_data$productivity_score >= median(lab3_data$productivity_score, na.rm = TRUE),
    "Aukštas produktyvumas", "Žemesnis produktyvumas")
)
```

Neparametrinių testų sąlygos

Neparametriniams testams nereikia normalumo prielaidos, todėl jie tinka tada, kai kintamųjų skirstiniai nėra normalūs arba kai norima remtis rangais. Svarbu, kad lyginamos grupės turėtų pakankamai stebėjimų, o poriniam Wilcoxon testui abu matavimai būtų atlikti tiems patiems studentams.

```
table(lab3_data$sleep_group)
```

```
##  
## Miega < 7 val. Miega >= 7 val.  
##      2471      2529
```

```
table(lab3_data$active_group)
```

```
##  
## Fiziškai aktyvūs    Mažiau aktyvūs  
##      2965      2035
```

```
table(lab3_data$internet_quality)
```

```
##  
## Average    Good    Poor  
##    1638    1722    1640
```

```
table(lab3_data$academic_level)
```

```
##  
## High School Postgraduate Undergraduate  
##    1672      1687      1641
```

```
sum(complete.cases(lab3_data[, c("screen_time_hours", "study_hours"))))
```

```
## [1] 5000
```

```
sum(complete.cases(lab3_data[, c("productivity_score", "academic_level"))))
```

```
## [1] 4929
```

H1, H3 ir H5 atveju stebėjimai yra nepriklausomi, nes lyginami skirtingi studentai. H4 atveju naudojamas porinis testas, nes kiekvienam studentui turime ir ekrano laiką, ir mokymosi laiką. Kruskal-Wallis testui H3 ir H5 tinka tai, kad lyginamos daugiau nei dvi nepriklausomos grupės.

Chi kvadrato kriterijų sąlygos

Chi kvadrato kriterijams tikėtini dažniai turi būti ne mažesni nei 5. H6 yra suderinamumo kriterijus, nes tikrinama, ar dviejų kategorijų pasiskirstymas atitinka iš anksto nurodytas proporcijas. H7 yra nepriklausomumo kriterijus, nes tikrinamas ryšys tarp dviejų kategorinių kintamųjų.

```
study_more_5_table <- table(lab3_data$study_more_5)  
study_more_5_table
```

```
##  
## Daugiau nei 5 val. Ne daugiau nei 5 val.  
##      2010      2990
```

```
chisq.test(study_more_5_table, p = c(0.5, 0.5))$expected
```

```
##      Daugiau nei 5 val. Ne daugiau nei 5 val.  
##      2500                2500
```

```
deadline_productivity_table <- table(lab3_data$upcoming_deadline,  
                                     lab3_data$high_productivity)  
deadline_productivity_table
```

```
##  
##      Aukštas produktyvumas Žemesnis produktyvumas  
##      Ne                1344                1133  
##      Taip              1123                1329
```

```
chisq.test(deadline_productivity_table)$expected
```

```
##  
##      Aukštas produktyvumas Žemesnis produktyvumas  
##      Ne                1239.756                1237.244  
##      Taip              1227.244                1224.756
```

Kadangi tikėtini dažniai yra didesni už 5, chi kvadrato suderinamumo ir nepriklausomumo kriterijus galima taikyti.

8. Statistinis tyrimas

H1. Pakankamas miegas ir egzamino rezultatai

```
aggregate(exam_score ~ sleep_group, data = lab3_data,  
          FUN = function(x) c(n = length(x),  
                              median = median(x, na.rm = TRUE),  
                              mean = mean(x, na.rm = TRUE)))
```

```
##      sleep_group exam_score.n exam_score.median exam_score.mean  
## 1  Miega < 7 val.   2161.00000           17.47000       18.54386  
## 2  Miega >= 7 val.   2383.00000           21.76000       22.44628
```

```
sleep_enough <- lab3_data$exam_score[lab3_data$sleep_group == "Miega >= 7 val."]  
sleep_less <- lab3_data$exam_score[lab3_data$sleep_group == "Miega < 7 val."]
```

```
h1_test <- wilcox.test(sleep_enough, sleep_less,  
                      alternative = "greater",  
                      exact = FALSE)
```

```
h1_test
```

```
##
## Wilcoxon rank sum test with continuity correction
##
## data: sleep_enough and sleep_less
## W = 3085499, p-value < 2.2e-16
## alternative hypothesis: true location shift is greater than 0
```

Gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$), todėl H_0 atmetama. Galima teigti, kad studentų, miegančių bent 7 valandas, egzamino rezultatai yra statistiškai reikšmingai aukštesni negu studentų, miegančių mažiau nei 7 valandas.

H2. Fiziškai aktyvių studentų koncentracijos indeksas

```
overall_focus_median <- median(lab3_data$focus_index, na.rm = TRUE)
active_focus <- lab3_data$focus_index[lab3_data$exercise_minutes > 60]

data.frame(
  bendra_mediana = overall_focus_median,
  aktyviu_studentu_n = length(active_focus),
  aktyviu_studentu_mediana = median(active_focus, na.rm = TRUE),
  aktyviu_studentu_vidurkis = mean(active_focus, na.rm = TRUE)
)
```

```
## bendra_mediana aktyviu_studentu_n aktyviu_studentu_mediana
## 1 29.43 2965 29.43
## aktyviu_studentu_vidurkis
## 1 29.38978
```

```
h2_test <- wilcox.test(active_focus,
  mu = overall_focus_median,
  alternative = "two.sided",
  exact = FALSE)

h2_test
```

```
##
## Wilcoxon signed rank test with continuity correction
##
## data: active_focus
## V = 2182326, p-value = 0.8249
## alternative hypothesis: true location is not equal to 29.43
```

Gauta p reikšmė yra didesnė už 0,05 ($p = 0,8249$), todėl H_0 neatmetama. Nėra pakankamo pagrindo teigti, kad fiziškai aktyvių studentų koncentracijos indeksas statistiškai reikšmingai skiriasi nuo bendro koncentracijos indekso lygio.

H3. Perdegimo lygis pagal interneto kokybę


```
aggregate(burnout_level ~ internet_quality, data = lab3_data,
          FUN = function(x) c(n = length(x),
                               median = median(x, na.rm = TRUE),
                               mean = mean(x, na.rm = TRUE),
                               IQR = IQR(x, na.rm = TRUE)))

## internet_quality burnout_level.n burnout_level.median burnout_level.mean
## 1 Average 1638.00000 45.68000 45.79960
## 2 Good 1722.00000 45.81000 45.70272
## 3 Poor 1640.00000 45.51500 45.33951
## burnout_level.IQR
## 1 18.83750
## 2 19.81000
## 3 20.21750
```

```
h3_test <- kruskal.test(burnout_level ~ internet_quality, data = lab3_data)
h3_test
```

```
##
## Kruskal-Wallis rank sum test
##
## data: burnout_level by internet_quality
## Kruskal-Wallis chi-squared = 0.88436, df = 2, p-value = 0.6426
```

Kruskal-Wallis testas leidžia palyginti daugiau nei dviejų nepriklausomų grupių pasiskirstymus. Gauta p reikšmė yra didesnė už 0,05 ($p = 0,6426$), todėl H_0 neatmetama. Nėra pakankamo pagrindo teigti, kad perdegimo lygio pasiskirstymas skiriasi pagal interneto kokybės grupes.

H4. Ekranų laikas ir mokymosi laikas

```
summary(lab3_data[, c("screen_time_hours", "study_hours")])
```

```
## screen_time_hours study_hours
## Min. : 1.00 Min. : 0.00
## 1st Qu.: 5.28 1st Qu.: 3.25
## Median : 6.95 Median : 4.53
## Mean : 6.98 Mean : 4.54
## 3rd Qu.: 8.71 3rd Qu.: 5.76
## Max. :15.30 Max. :11.84
```

```
h4_test <- wilcox.test(lab3_data$screen_time_hours,
                       lab3_data$study_hours,
                       paired = TRUE,
                       alternative = "greater",
                       exact = FALSE)
h4_test
```

```
##
```

```
## Wilcoxon signed rank test with continuity correction
##
## data: lab3_data$screen_time_hours and lab3_data$study_hours
## V = 10788965, p-value < 2.2e-16
## alternative hypothesis: true location shift is greater than 0
```

Gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$), todėl H_0 atmetama. Kadangi ekrano laiko mediana yra 6,95 val., o mokymosi laiko mediana yra 4,53 val., galima teigti, kad studentai statistiškai reikšmingai daugiau laiko praleidžia prie ekrano negu mokosi.

H5. Produktyvumo balas pagal akademinį lygį

```
aggregate(productivity_score ~ academic_level, data = lab3_data,
  FUN = function(x) c(n = length(x),
    median = median(x, na.rm = TRUE),
    mean = mean(x, na.rm = TRUE),
    IQR = IQR(x, na.rm = TRUE)))
```

```
## academic_level productivity_score.n productivity_score.median
## 1 High School 1649.00000 37.21000
## 2 Postgraduate 1657.00000 37.23000
## 3 Undergraduate 1623.00000 37.20000
## productivity_score.mean productivity_score.IQR
## 1 37.75201 23.33000
## 2 37.88719 23.28000
## 3 37.72978 23.68000
```

```
h5_test <- kruskal.test(productivity_score ~ academic_level, data = lab3_data)
h5_test
```

```
##
## Kruskal-Wallis rank sum test
##
## data: productivity_score by academic_level
## Kruskal-Wallis chi-squared = 0.15413, df = 2, p-value = 0.9258
```

Kruskal-Wallis testas tikrina, ar produktyvumo balo pasiskirstymas skiriasi tarp kelių akademinio lygio grupių. Gauta p reikšmė yra didesnė už 0,05 ($p = 0,9258$), todėl H_0 neatmetama. Nėra pakankamo pagrindo teigti, kad produktyvumo balo pasiskirstymas skiriasi pagal akademinį lygį.

H6. Studentų, besimokančių daugiau nei 5 valandas, dalis

```
study_more_5_table
```

```
##
## Daugiau nei 5 val. Ne daugiau nei 5 val.
## 2010 2990
```

```
prop.table(study_more_5_table)
```

```
##
##      Daugiau nei 5 val. Ne daugiau nei 5 val.
##      0.402                0.598
```

```
h6_test <- chisq.test(study_more_5_table, p = c(0.5, 0.5))
h6_test
```

```
##
## Chi-squared test for given probabilities
##
## data:  study_more_5_table
## X-squared = 192.08, df = 1, p-value < 2.2e-16
```

Chi kvadrato suderinamumo kriterijus tikrina, ar studentų, besimokančių daugiau nei 5 valandas, ir ne daugiau nei 5 valandas besimokančių studentų proporcijos atitinka santykį 50 % ir 50 %. Gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$), todėl H_0 atmetama. Studentų, besimokančių daugiau nei 5 valandas per dieną, dalis yra 40,2 %, todėl ji statistiškai reikšmingai skiriasi nuo 50 %.

H7. Artėjantis atsiskaitymas ir aukštas produktyvumas

```
deadline_productivity_table
```

```
##
##      Aukštas produktyvumas Žemesnis produktyvumas
## Ne      1344                1133
## Taip    1123                1329
```

```
prop.table(deadline_productivity_table, margin = 1)
```

```
##
##      Aukštas produktyvumas Žemesnis produktyvumas
## Ne      0.5425918          0.4574082
## Taip    0.4579935          0.5420065
```

```
h7_test <- chisq.test(deadline_productivity_table)
h7_test
```

```
##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  deadline_productivity_table
## X-squared = 34.938, df = 1, p-value = 3.404e-09
```

Chi kvadrato nepriklausomumo kriterijus tikrina, ar aukšto produktyvumo pasiekimo proporcija priklauso nuo artėjančio atsiskaitymo. Gauta p reikšmė yra mažesnė už 0,05 ($p = 3,404e-09$), todėl H_0 atmetama. Galima teigti, kad aukšto produktyvumo pasiekimo proporcija statistiškai reikšmingai priklauso nuo to, ar studentui artėja atsiskaitymas. Studentų, kuriems atsiskaitymas neartėja, aukšto produktyvumo dalis yra 54,26 %, o studentų, kuriems atsiskaitymas artėja, ši dalis yra 45,80 %.

9. Išvada

Atlikus trečio laboratorinio darbo statistinį tyrimą, hipotezės patikrintos neparametriniais arba chi kvadrato kriterijais. Visiems testams taikytas reikšmingumo lygmuo $\alpha = 0,05$.

```
isvados <- data.frame(  
  Hipoteze = c("H1", "H2", "H3", "H4", "H5", "H6", "H7"),  
  Testas = c(  
    "Mann-Whitney-Wilcoxon",  
    "Vienos imties Wilcoxon",  
    "Kruskal-Wallis",  
    "Porinis Wilcoxon",  
    "Kruskal-Wallis",  
    "Chi kvadrato suderinamumo",  
    "Chi kvadrato nepriklausomumo"  
  ),  
  P_reiksme = c(  
    "< 2,2e-16",  
    "0,8249",  
    "0,6426",  
    "< 2,2e-16",  
    "0,9258",  
    "< 2,2e-16",  
    "3,404e-09"  
  ),  
  Sprendimas = c(  
    "H0 atmetama",  
    "H0 neatmetama",  
    "H0 neatmetama",  
    "H0 atmetama",  
    "H0 neatmetama",  
    "H0 atmetama",  
    "H0 atmetama"  
  )  
)  
isvados
```

##	Hipoteze	Testas	P_reiksme	Sprendimas
## 1	H1	Mann-Whitney-Wilcoxon	< 2,2e-16	H0 atmetama
## 2	H2	Vienos imties Wilcoxon	0,8249	H0 neatmetama
## 3	H3	Kruskal-Wallis	0,6426	H0 neatmetama
## 4	H4	Porinis Wilcoxon	< 2,2e-16	H0 atmetama
## 5	H5	Kruskal-Wallis	0,9258	H0 neatmetama
## 6	H6	Chi kvadrato suderinamumo	< 2,2e-16	H0 atmetama
## 7	H7	Chi kvadrato nepriklausomumo	3,404e-09	H0 atmetama

Apibendrinant rezultatus:

Hipotezė 1: Atmetama nulinė hipotezė, nes gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$). Egzamino rezultatai statistiškai reikšmingai skiriasi tarp grupių. Studentai, kurie miega ≥ 7 valandas, turi aukštesnius egzamino rezultatus (22,45) nei tie, kurie miega < 7 valandas (18,54). Tai patvirtina, kad pakankamas miegas teigiamai veikia egzamino rezultatus.

Hipotezė 2: Nulinė hipotezė neatmetama, nes gauta p reikšmė yra didesnė už 0,05 ($p = 0,8249$). Fiziškai aktyvių studentų koncentracijos indeksas statistiškai reikšmingai nesiskiria nuo bendro koncentracijos indekso lygio. Fiziškai aktyvių studentų koncentracijos indekso mediana yra 29,43, o bendra koncentracijos indekso mediana taip pat lygi 29,43. Todėl negalima teigti, kad fizinis aktyvumas šiame duomenų rinkinyje yra susijęs su kitokiu koncentracijos indeksu.

Hipotezė 3: Nulinė hipotezė neatmetama, nes gauta p reikšmė yra didesnė už 0,05 ($p = 0,6426$). Perdegimo lygio pasiskirstymas pagal interneto kokybės grupes statistiškai reikšmingai nesiskiria. Tai reiškia, kad pagal šiuos duomenis interneto kokybė nėra susijusi su reikšmingais perdegimo lygio skirtumais.

Hipotezė 4: Atmetama nulinė hipotezė, nes gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$). Ekranų laikas ir mokymosi laikas statistiškai reikšmingai skiriasi. Studentai prie ekranų praleidžia daugiau laiko: ekranų laiko mediana yra 6,95 val., o mokymosi laiko mediana yra 4,53 val. Tai rodo, kad studentai vidutiniškai daugiau laiko praleidžia prie ekranų negu mokosi.

Hipotezė 5: Nulinė hipotezė neatmetama, nes gauta p reikšmė yra didesnė už 0,05 ($p = 0,9258$). Produktyvumo balo pasiskirstymas pagal akademinį lygį statistiškai reikšmingai nesiskiria. Todėl nėra pakankamo pagrindo teigti, kad skirtingų akademinį lygį studentai pasižymi skirtingu produktyvumo balu.

Hipotezė 6: Atmetama nulinė hipotezė, nes gauta p reikšmė yra mažesnė už 0,05 ($p < 2,2e-16$). Studentų, besimokančių daugiau nei 5 valandas per dieną, dalis statistiškai reikšmingai skiriasi nuo 50 %. Iš viso daugiau nei 5 valandas mokosi 2010 studentų, tai sudaro 40,2 %, o ne daugiau nei 5 valandas mokosi 2990 studentų, tai sudaro 59,8 %. Todėl galima teigti, kad daugiau nei 5 valandas per dieną besimokančių studentų dalis nėra lygi pusei visų studentų.

Hipotezė 7: Atmetama nulinė hipotezė, nes gauta p reikšmė yra mažesnė už 0,05 ($p = 3,404e-09$). Aukšto produktyvumo pasiekimo proporcija statistiškai reikšmingai priklauso nuo to, ar studentui artėja atsiskaitymas. Studentų, kuriems atsiskaitymas neartėja, aukšto produktyvumo dalis yra 54,26 %, o studentų, kuriems atsiskaitymas artėja, ši dalis yra 45,80 %. Tai rodo, kad artėjantis atsiskaitymas yra susijęs su mažesne aukšto produktyvumo proporcija.