

Statistika: 2 laboratorinis darbas

Junior Statistikai

Naudotos bibliotekos:

```
library(readxl)
library(dplyr)
library(tidyr)
library(e1071)
library(ggplot2)
```

Duomenų nuskaitymas:

```
duomenys <- read_excel("Duomenys.xlsx", sheet = "duomenys", range = "A1:U5001")

duomenys <- duomenys %>%
  mutate(across(c(1, 2, 5:15, 17:21), ~as.numeric(.))) %>%
  mutate(exam_score = na_if(exam_score, 1.0)) %>%
  mutate(productivity_score = na_if(productivity_score, 1.0))
```

1. Aprašykite turimus duomenis, nurodykite duomenų šaltinį.

Pasirinktas duomenų rinkinys apie įvairius mokinių, studentų mokymosi elgsenos ir produktyvumo aspektus. Duomenų šaltinį sudaro 5000 įrašų (5000 studentų/mokinių). Duomenų rinkinyje pateikiama informacija apie mokymosi valandas, miego įpročius, socialinių tinklų naudojimą, streso lygį ir akademinius rezultatus.

Kiekybiniai kintamieji:

1. Studento amžius (age);
2. Studijų valandos (study_hours);
3. Savarankiškų studijų valandos (self_study_hours);
4. Nuotolinių studijų valandos (online_study_hours);
5. Naudojimosi socialiniais tinklais laikas valandomis (social_media_hours);
6. Laikas praleistas žaidžiant kompiuteriu (gaming_hours);
7. Miego valandos (sleep_hours);
8. Ekrano laiko valandos (screen_time_hours);
9. Sportavimas minutėmis (exercise_minutes);
10. Kofeino suvartojimas miligramais (caffeine_intake_mg);
11. Psichikos sveikatos balas (mental_health_score);

12. Koncentracijos indeksas (focus_index);
13. Perdegimo lygis (burnout_level);
14. Produktyvumo lygis (productivity_score);
15. Egzamino rezultatas (exam_score).


Ranginiai kintamieji:

1. Lytis (gender) – „Male“, „Female“, „Other“;
2. Studijų lygis (academic_level) – „Undergraduate“, „High school“, „Postgraduate“;
3. Darbas ne visą darbo dieną (part_time_job) – 1 (turi darbą), 0 (neturi darbo);
4. Artėjantis atsiskaitymas (upcoming_deadline) – 1 (artėja atsiskaitymo data), 0 (nėra atsiskaitymo datos);
5. Interneto kokybė (internet_quality) – „Poor“, „Average“, „Good“.

2. Išbrėžkite turimų duomenų grafikus (parinkite tinkamiausius).


Egzamino rezultatų (exam_score) pasiskirstymas - histograma:

```
# Histograma 1 - egzamino rezultatai (exam_score)
# Histograma 2 - produktyvumo lygis (productivity_score)
# Histograma 3 - perdegimo lygis (burnout_level)
# Histograma 4 - koncentracijos indeksas (focus_index)
duomenys %>%
  dplyr::select(exam_score, productivity_score, burnout_level, focus_index) %>%
  pivot_longer(cols = everything(),
               names_to = "kintamasis",
               values_to = "reiksme") %>%
  ggplot(aes(x = reiksme)) +
  geom_histogram(binwidth = 3, fill = "steelblue", color = "white") +
  facet_wrap(~kintamasis, scales = "free",
            labeller = labeller(kintamasis = c(
              exam_score = "Egzamino rezultatas",
              productivity_score = "Produktyvumo lygis",
              burnout_level = "Perdegimo lygis",
              focus_index = "Koncentracijos indeksas"
            ))) +
  labs(x = "Reikšmė", y = "Dažnis") +
  theme_minimal()
```




```
# Sklaidos diagrama 1 - ryšys tarp mokymosi valandų ir egzamino rezultato
ggplot(duomenys, aes(x = study_hours, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp mokymosi valandų ir egzamino rezultato",
    x = "Mokymosi valandos",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp mokymosi valandų ir egzamino rezultato




```
# Sklaidos diagrama 2 - ryšys tarp produktyvumo lygio ir egzamino rezultato
ggplot(duomenys, aes(x = productivity_score, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp produktyvumo lygio ir egzamino rezultato",
    x = "Produktyvumo lygis",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp produktyvumo lygio ir egzamino rezultato




```
# Sklaidos diagrama 3 - ryšys tarp perdegimo lygio ir egzamino rezultato
ggplot(duomenys, aes(x = burnout_level, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp perdegimo lygio ir egzamino rezultato",
    x = "Perdegimo lygis",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp perdegimo lygio ir egzamino rezultato



```
# Sklaidos diagrama 4 - ryšys tarp koncentracijos indekso ir egzamino rezultato
ggplot(duomenys, aes(x = focus_index, y = exam_score)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE, color = "red") +
  labs(
    title = "Ryšys tarp koncentracijos indekso ir egzamino rezultato",
    x = "Koncnetracijos indeksas",
    y = "Egzamino rezultatas"
  ) +
  theme_minimal()
```

Ryšys tarp koncentracijos indekso ir egzamino rezultato




```
# Duomenų pertvarkymas grafikams
```


```
duomenys$part_time_job <- factor(duomenys$part_time_job,  
                                levels = c(0, 1),  
                                labels = c("Ne", "Taip"))  
duomenys$upcoming_deadline <- factor(duomenys$upcoming_deadline,  
                                    levels = c(0, 1),  
                                    labels = c("Ne", "Taip"))
```

```
# Boxplot 1 - perdegimo lygis pagal artėjančius atsiskaitymus
```

```
ggplot(duomenys, aes(x = upcoming_deadline, y = burnout_level, fill = upcoming_deadline)) +  
  geom_boxplot(alpha = 0.7) +  
  labs(  
    title = "Perdegimo lygis pagal artėjančius atsiskaitymus",  
    x = "Ar artėja atsiskaitymas",  
    y = "Perdegimo lygis",  
    fill = "Atsiskaitymas"  
  ) +  
  theme_minimal() +  
  scale_fill_brewer(palette = "Set2")
```



```
# Boxplot 2 - perdegimo lygis pagal tai ar studentas turi darbą
ggplot(duomenys, aes(x = part_time_job, y = burnout_level, fill = part_time_job)) +
  geom_boxplot(alpha = 0.7) +
  labs(
    title = "Perdegimo lygis pagal studento darbą",
    x = "Ar turi darbą?",
    y = "Perdegimo lygis",
    fill = "Darbas"
  ) +
  theme_minimal() +
  scale_fill_brewer(palette = "Set2")
```



3. Apskaičiuokite pagrindines skaitines charakteristikas kiekybiniam kintamiesiems.

```
kiekybiniai <- c(2, 5:13, 17:21)
funkcijos <- list(
  Vidurkis = ~mean(.x, na.rm = TRUE),
  Min = ~min(.x, na.rm = TRUE),
  Max = ~max(.x, na.rm = TRUE),
  Dispersija = ~var(.x, na.rm = TRUE),
  StNuokrypis = ~sd(.x, na.rm = TRUE),
  Q1 = ~quantile(.x, 0.25, na.rm = TRUE),
  Q2 = ~median(.x, na.rm = TRUE),
  Q3 = ~quantile(.x, 0.75, na.rm = TRUE),
  IQR = ~IQR(.x, na.rm = TRUE),
  Asimetrija = ~skewness(.x, na.rm = TRUE),
  Eksecesas = ~kurtosis(.x, na.rm = TRUE)
)

ch <- duomenys %>%
  dplyr::select(all_of(c(2, 5:13, 17:21))) %>%
  summarise(across(everything(), funkcijos)) %>%
  pivot_longer(everything(),
    names_to = c("Kintamasis", "Charakteristika"),
    names_sep = "_(?=[^_]+$)" %>%
```

```

pivot_wider(names_from = Charakteristika, values_from = value)

print(ch)

## # A tibble: 15 x 12
##   Kintamasis Vidurkis   Min   Max Dispersija StNuokrypis   Q1   Q2   Q3
##   <chr>         <dbl> <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl> <dbl>
## 1 age          20.5  16    25     8.24    2.87  18    20    23
## 2 study_hours   4.54  0    11.8    3.32    1.82  3.25  4.53  5.76
## 3 self_study~   2.48  0     7.41    1.39    1.18  1.66  2.48  3.29
## 4 online_cla~   2.01  0     6      0.968    0.984  1.32  2.01  2.69
## 5 social_med~   3.00  0     8.28    2.15    1.47  1.99  2.98  4.03
## 6 gaming_hou~   1.56  0     5.64    1.23    1.11  0.67  1.49  2.34
## 7 sleep_hours   7.02  4     10     1.35    1.16  6.24  7.01  7.81
## 8 screen_tim~   6.98  1    15.3    6.18    2.49  5.28  6.95  8.71
## 9 exercise_m~   74.5  0    149    1843.    42.9  37    75   112
## 10 caffeine_i~  251.   0    499   20691.   144.  129   252   376
## 11 mental_he~   5.51  1     10     8.23    2.87  3     5     8
## 12 focus_index  29.4  1    63.5   99.3    9.96  22.6  29.4  36.2
## 13 burnout_le~  45.6  1    97.6  203.    14.2  35.7  45.7  55.4
## 14 productivi~  37.8  1.04  98.0  269.    16.4  25.9  37.2  49.4
## 15 exam_score   20.6  1.01  64.1  127.    11.3  11.9  19.6  28.4
## # i 3 more variables: IQR <dbl>, Asimetrija <dbl>, Eksecesas <dbl>

```

4. Sudarykite dažnių lentelės kategoriniams kintamiesiems.

```

kategoriniai <- c(3:4, 14:16)

for (kol in kategoriniai) {
  pav <- colnames(duomenys)[kol]
  cat("\n", pav, "\n")

  lentele <- duomenys %>%
    count(.data[[pav]]) %>%
    rename(Kategorija = 1, Daznis = n) %>%
    mutate(Procentai = round(Daznis / sum(Daznis) * 100, 2))

  print(lentele)
}

```

```

##
## gender
## # A tibble: 3 x 3
##   Kategorija Daznis Procentai
##   <chr>      <int>   <dbl>
## 1 Female    1630    32.6
## 2 Male      1719    34.4
## 3 Other     1651    33.0
##
## academic_level
## # A tibble: 3 x 3

```

```
##   Kategorija      Daznis Procentai
##   <chr>          <int>    <dbl>
## 1 High School    1672     33.4
## 2 Postgraduate   1687     33.7
## 3 Undergraduate  1641     32.8
##
##   part_time_job
## # A tibble: 2 x 3
##   Kategorija Daznis Procentai
##   <fct>      <int>    <dbl>
## 1 Ne        2509     50.2
## 2 Taip      2491     49.8
##
##   upcoming_deadline
## # A tibble: 2 x 3
##   Kategorija Daznis Procentai
##   <fct>      <int>    <dbl>
## 1 Ne        2493     49.9
## 2 Taip      2507     50.1
##
##   internet_quality
## # A tibble: 3 x 3
##   Kategorija Daznis Procentai
##   <chr>      <int>    <dbl>
## 1 Average    1638     32.8
## 2 Good       1722     34.4
## 3 Poor       1640     32.8
```

5. Suformuluokite tyrimo hipotezes.

H1. Pakankamas miegas (≥ 7 h) gerina egzamino rezultatus (dviejų imčių t-testas).

H0: Studentų miegančių ≥ 7 ir < 7 valandas egzamino rezultatai vidutiniškai nesiskiria.

H1: Studentų, miegančių ≥ 7 valandas egzamino rezultatai vidutiniškai yra aukštesni nei < 7 valandas miegančių studentų.

H2. Ar fiziškai aktyvių studentų koncentracijos indeksas skiriasi nuo bendro koncentracijos indekso vidurkio (vienos imties t-testas).

H0: Fiziškai aktyvių studentų ($\text{exercise_minutes} > 60$) koncentracijos indeksas nesiskiria nuo bendro koncentracijos indekso vidurkio.

H1: Fiziškai aktyvių studentų ($\text{exercise_minutes} > 60$) koncentracijos indeksas skiriasi nuo bendro koncentracijos indekso vidurkio.

H3. Ar mokymosi intensyvumas veikia perdegimo lygio nevienodumą (dviejų imčių dispersijos testas).

H0: Perdegimo lygio dispersijos tarp skirtingo mokymosi intensyvumo grupių yra lygios.

H1: Dispersijos skiriasi.

H4. Ar studentai praleidžia daugiau laiko prie ekrano (screen_time_hours), nei skiria laiko mokymuisi (study_hours)? (porinis t-testas)

H0: Vidutinis ekrano laikas ir vidutinis mokymosi laikas nesiskiria (screen_time_hours = study_hours).

H1: Studentai vidutiniškai praleidžia daugiau laiko prie ekrano nei mokosi (screen_time_hours > study_hours).

H5. Ar mokymasis daugiau valandų susijęs su geresniu egzamino rezultatu (Pearson koreliacijos testas).

H0: Tarp study_hours ir exam_score nėra tiesinės koreliacijos.

H1: Tarp study_hours ir exam_score yra teigiama tiesinė koreliacija.

H6. Ar studentų besimokančių daugiau nei 5 valandas per dieną, dalis yra lygi 50% (vienos imties proporcijų testas).

H0: Studentų, besimokančių daugiau nei 5 valandas (study_hours>5) per dieną, dalis yra lygi 50%.

H1: Studentų, besimokančių daugiau nei 5 valandas (study_hours>5) per dieną, dalis nelygi 50%.

H7. Ar artėjančio atsiskaitymo (upcoming_deadline) grupėse skiriasi aukšto produktyvumo pasiekimo proporcija (dviejų imčių proporcijų)

H0: Aukšto produktyvumo pasiekimo proporcija nesiskiria tarp studentų, kuriems artėja atsiskaitymas, ir tų, kuriems neartėja.

H1: Aukšto produktyvumo pasikimas skiriasi tarp šių dviejų grupių.

6. Užrašykite kokius testus parinkote hipotezių tikrinimui.

H1 - t-testas (dviejų imčių).

H2 - t-testas (vienos imties).

H3 - dispersijų testas (var.test).

H4 - porinis t-testas.

H5 - koreliacijos testas (Pearson).

H6 - vienos imties proporcijų testas.

H7 - dviejų imčių proporcijų testas.

7. Patikrinkite, ar kintamieji tenkina būtinas sąlygas testų taikymui.

```
# Papildomi kintamieji hipotezėms
duomenys <- duomenys %>%
  mutate(
    gerai_miega = factor(
      ifelse(sleep_hours >= 7, ">=7h", "<7h"),
      levels = c("<7h", ">=7h")
    )
  )
```

```

),
aktyvus = factor(
  ifelse(exercise_minutes > 60, "Aktyvus", "Neaktyvus"),
  levels = c("Neaktyvus", "Aktyvus")
),
mokymosi_grupe = factor(
  ifelse(study_hours > median(study_hours, na.rm = TRUE),
    "Daug mokosi", "Mažai mokosi"),
  levels = c("Mažai mokosi", "Daug mokosi")
),
auksti_rezultatai = factor(
  ifelse(exam_score > median(exam_score, na.rm = TRUE), 1, 0),
  levels = c(0, 1),
  labels = c("Ne", "Taip")
),
aukštas_produktyvumas = factor(
  ifelse(productivity_score > median(productivity_score, na.rm = TRUE), 1, 0),
  levels = c(0, 1),
  labels = c("Ne(AP)", "Taip(AP)")
)
)
)

```

```

# H1
# Reikalinga, kad turimi duomenys būtų pasiskirtę normaliuoju skirstiniu
shapiro.test(duomenys$exam_score[duomenys$gerai_miega == ">=7h"])

```

```

##
## Shapiro-Wilk normality test
##
## data: duomenys$exam_score[duomenys$gerai_miega == ">=7h"]
## W = 0.98552, p-value = 7.556e-15

```

```
shapiro.test(duomenys$exam_score[duomenys$gerai_miega == "<7h"])

```

```

##
## Shapiro-Wilk normality test
##
## data: duomenys$exam_score[duomenys$gerai_miega == "<7h"]
## W = 0.97145, p-value < 2.2e-16

```

```
table(duomenys$gerai_miega)
```

```

##
## <7h >=7h
## 2471 2529

```

Kadangi abejais atvejais $p\text{-value} < 0.05$ - Shapiro testas teigia, kad duomenys nėra normalūs. Tačiau $n > 50$ dėl to t-testą vis tiek galima naudoti papildomai netransformuojant.

```
# H2
# Reikalinga, kad turimi duomenys būtų pasiskirtę normaliuoju skirstiniu
shapiro.test(duomenys$focus_index[duomenys$aktyvus == "Aktyvus"])
```

```
##
## Shapiro-Wilk normality test
##
## data: duomenys$focus_index[duomenys$aktyvus == "Aktyvus"]
## W = 0.99926, p-value = 0.2837
```

```
table(duomenys$aktyvus)
```

```
##
## Neaktyvus Aktyvus
## 2035 2965
```

Kadangi $p\text{-value} > 0.05$ - turimi duomenys yra pasiskirtę normaliuoju skirstiniu ir yra tinkami atlikti H2 testą.

```
# H3
# Reikalinga, kad turimi duomenys būtų pasiskirtę normaliuoju skirstiniu
by(duomenys$burnout_level, duomenys$mokymosi_grupe, shapiro.test)
```

```
## duomenys$mokymosi_grupe: Mažai mokosi
##
## Shapiro-Wilk normality test
##
## data: dd[x, ]
## W = 0.99923, p-value = 0.3908
##
## -----
## duomenys$mokymosi_grupe: Daug mokosi
##
## Shapiro-Wilk normality test
##
## data: dd[x, ]
## W = 0.99906, p-value = 0.2137
```

Kadangi $p\text{-value} > 0.05$ - naudojami duomenys pasiskirtę normaliuoju skirstiniu ir yra tinkami dispersijų testui taikyti.

```
# H4 - sąlygų tikrinimas (porinis t-testas)
skirtumai <- duomenys$screen_time_hours - duomenys$study_hours
shapiro.test(skirtumai)
```

```
##
## Shapiro-Wilk normality test
##
## data: skirtumai
## W = 0.99878, p-value = 0.0008726
```

```
length(skirtumai[!is.na(skirtumai)])
```

```
## [1] 5000
```

Kadangi $p\text{-value} < 0.05$ – Shapiro testas teigia, kad skirtumai nėra pasiskirstę normaliai. Tačiau $n=5000 > 50$, todėl porinis t-testas vis tiek gali būti taikomas.

```
# H5 - Pearson koreliacija  
shapiro.test(duomenys$study_hours)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: duomenys$study_hours  
## W = 0.99847, p-value = 9.601e-05
```

```
shapiro.test(duomenys$exam_score)
```

```
##  
## Shapiro-Wilk normality test  
##  
## data: duomenys$exam_score  
## W = 0.97904, p-value < 2.2e-16
```

```
sum(!is.na(duomenys$study_hours) & !is.na(duomenys$exam_score))
```

```
## [1] 4544
```

Kadangi $p\text{-value} < 0.05$, tai abejais atvejais kintamųjų skirstiniai nėra normalieji, bet $n > 50$, tai duomenys tinkami atlikti koreliacijos testą.

```
# H6 - vienos imties proporcijos testas  
n_viso <- sum(!is.na(duomenys$study_hours))  
n_daugiau5 <- sum(duomenys$study_hours > 5, na.rm = TRUE)  
  
cat("n * p =", n_viso * 0.5, "\n")
```

```
## n * p = 2500
```

```
cat("n * (1-p) =", n_viso * 0.5, "\n")
```

```
## n * (1-p) = 2500
```

$np=2500 > 5$ ir $n(1-p)=2500 > 5$ todėl galima naudoti vienos imties proporcijų testą.

```
#H7 duomenų persitvarkymas
```

```
# H7 - proporcijų testas (miegas ir aukštas rezultatas)
table(duomenys$upcoming_deadline, duomenys$aukštas_produktyvumas)
```

```
##
##      Ne(AP) Taip(AP)
## Ne      1135      1342
## Taip    1331      1121
```

```
prop.table(table(duomenys$upcoming_deadline, duomenys$aukštas_produktyvumas))
```

```
##
##      Ne(AP) Taip(AP)
## Ne  0.2302698 0.2722662
## Taip 0.2700345 0.2274295
```

Kadangi kiekvienoje grupėje $n > 5$ ir proporcijos skiriasi, tai duomenys yra tinkami atlikti proporcijų testą.

8. Atlikite statistinį tyrimą savo suformuluotoms hipotezėms.

```
# H1 - dviejų imčių t-testas
levels(duomenys$gerai_miega)
```

```
## [1] "<7h" ">=7h"
```

```
var.test(exam_score ~ gerai_miega, data = duomenys)
```

```
##
## F test to compare two variances
##
## data: exam_score by gerai_miega
## F = 0.88256, num df = 2160, denom df = 2382, p-value = 0.002995
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
##  0.8128375 0.9584164
## sample estimates:
## ratio of variances
##      0.8825564
```

```
t.test(exam_score ~ gerai_miega, data = duomenys, var.equal = FALSE, alternative = "less")
```

```
##
## Welch Two Sample t-test
##
## data: exam_score by gerai_miega
## t = -11.875, df = 4536.3, p-value < 2.2e-16
## alternative hypothesis: true difference in means between group <7h and group >=7h is less than 0
## 95 percent confidence interval:
##      -Inf -3.361746
## sample estimates:
## mean in group <7h mean in group >=7h
##      18.54386      22.44628
```

H0: atmetama ($p\text{-value} < 0.05$). Studentai, miegantys ≥ 7 valandas, turi statistiškai reikšmingai aukštesnius egzamino rezultatus (22.45) nei miegantys < 7 valandas (18.54).

```
# H2 - vienos imties t-testas
levels(duomenys$aktyvus)
```

```
## [1] "Neaktyvus" "Aktyvus"
```

```
t.test(duomenys$focus_index[duomenys$aktyvus == "Aktyvus"], mu = mean(duomenys$focus_index, na.rm = TRUE),
```

```
##
## One Sample t-test
##
## data: duomenys$focus_index[duomenys$aktyvus == "Aktyvus"]
## t = -0.22712, df = 2964, p-value = 0.8203
## alternative hypothesis: true mean is not equal to 29.43162
## 95 percent confidence interval:
## 29.02861 29.75095
## sample estimates:
## mean of x
## 29.38978
```

H0: neatmetama ($p\text{-value} > 0.05$). Fiziškai aktyvių studentų koncentracijos indekso vidurkis (29.39) statistiškai reikšmingai nesiskiria nuo bendro populiacijos vidurkio (29.43).

```
# H3 - dispersijų testas
var.test(burnout_level ~ mokymosi_grupe, data = duomenys, alternative = "two.sided")
```

```
##
## F test to compare two variances
##
## data: burnout_level by mokymosi_grupe
## F = 0.99623, num df = 2500, denom df = 2498, p-value = 0.9247
## alternative hypothesis: true ratio of variances is not equal to 1
## 95 percent confidence interval:
## 0.9210768 1.0775096
## sample estimates:
## ratio of variances
## 0.9962281
```

H0: neatmetama ($p\text{-value} > 0.05$). Perdegimo lygio dispersijos tarp skirtingo mokymosi intensyvumo grupių statistiškai reikšmingai nesiskiria.

```
#H4 - porinis t-testas
t.test(duomenys$screen_time_hours, duomenys$study_hours,
       paired = TRUE,
       alternative = "greater")
```

```
##
## Paired t-test
##
```

```
## data: duomenys$screen_time_hours and duomenys$study_hours
## t = 55.377, df = 4999, p-value < 2.2e-16
## alternative hypothesis: true mean difference is greater than 0
## 95 percent confidence interval:
## 2.367506      Inf
## sample estimates:
## mean difference
## 2.439994
```

H0: atmetama. Studentai vidutiniškai praleidžia statistiškai reikšmingai daugiau laiko prie ekrano (screen_time_hours) nei mokosi (study_hours). Vidutinis skirtumas yra 2.44 valandos – tiek daugiau laiko skiriama ekranui nei mokymuisi per dieną.

```
# H5 - Pearson koreliacija
cor.test(duomenys$study_hours, duomenys$exam_score, method = "pearson",
         alternative = "greater")
```

```
##
## Pearson's product-moment correlation
##
## data: duomenys$study_hours and duomenys$exam_score
## t = 35.301, df = 4542, p-value < 2.2e-16
## alternative hypothesis: true correlation is greater than 0
## 95 percent confidence interval:
## 0.4446284 1.0000000
## sample estimates:
## cor
## 0.4639979
```

H0: atmetama ($p\text{-value} < 0.05$). Tarp mokymosi valandų ir egzamino rezultato yra statistiškai reikšminga teigiama koreliacija ($r=0.46$). Tai reiškia, kad didėjant mokymosi valandų skaičiui, egzamino rezultatai taip pat didėja.

```
# H6 - Vienos imties proporcijų testas (study_hours > 5)
n_viso <- sum(!is.na(duomenys$study_hours))
n_daugiau5 <- sum(duomenys$study_hours > 5, na.rm = TRUE)

prop.test(n_daugiau5, n_viso, p = 0.5, alternative = "two.sided")
```

```
##
## 1-sample proportions test with continuity correction
##
## data: n_daugiau5 out of n_viso, null probability 0.5
## X-squared = 191.69, df = 1, p-value < 2.2e-16
## alternative hypothesis: true p is not equal to 0.5
## 95 percent confidence interval:
## 0.3883906 0.4157609
## sample estimates:
## p
## 0.402
```

H0: atmetama ($p\text{-value} < 0.05$). Studentų, besimokančių ilgiau nei 5 valandos per dieną, dalis yra 40.2%, kas statistiškai reikšmingai skiriasi nuo 50%. Tai reiškia, kad dauguma studentų mokosi 5 ir mažiau valandų per dieną.

```
# H7
prop.test(table(duomenys$upcoming_deadline, duomenys$aukštas_produktyvumas),
          alternative = "two.sided")

##
## 2-sample test for equality of proportions with continuity correction
##
## data:  table(duomenys$upcoming_deadline, duomenys$aukštas_produktyvumas)
## X-squared = 34.945, df = 1, p-value = 3.392e-09
## alternative hypothesis: two.sided
## 95 percent confidence interval:
##  -0.1128296 -0.0563836
## sample estimates:
##      prop 1      prop 2
## 0.4582156 0.5428222
```

H0: atmetama (p-value < 0.05). Aukšto produktyvumo pasiekimo proporcija statistiškai reikšmingai skiriasi tarp grupių. Studentų, kuriems artėja atsiskaitymas, aukšto produktyvumo proporcija yra 45.8%, o studentų, kuriems neartėja atsiskaitymas – 54.3%. Tai reiškia, kad artėjantis atsiskaitymas yra susijęs su mažesniu produktyvumu.

9. Pateikite tyrimo atsakymą.

Hipotezė 1: Atmetama nulinė hipotezė. Egzamino rezultatai statistiškai reikšmingai skiriasi tarp grupių. Studentai, kurie miega ≥ 7 valandas, turi aukštesnius egzamino rezultatus (22.45) nei tie, kurie miega < 7 valandas (18.54). Tai patvirtina, kad pakankamas miegas teigiamai veikia egzamino rezultatus.

Hipotezė 2: Nulinė hipotezė neatmetama. Fiziškai aktyvių studentų koncentracijos indekso vidurkis (29.39) statistiškai reikšmingai nesiskiria nuo bendro populiacijos vidurkio (29.43). Fizinis aktyvumas neturi reikšmingo poveikio koncentracijos indeksui.

Hipotezė 3: Nulinė hipotezė neatmetama. Perdegimo lygio dispersijos tarp skirtingo mokymosi intensyvumo grupių statistiškai reikšmingai nesiskiria. Mokymosi intensyvumas neturi reikšmingo poveikio perdegimo lygio nevienodumui.

Hipotezė 4: Nulinė hipotezė atmetama. Studentai vidutiniškai praleidžia statistiškai reikšmingai daugiau laiko prie ekrano (screen_time_hours) nei mokosi (study_hours). Vidutinis skirtumas yra 2.44 valandos - tiek daugiau laiko skiriama ekranui nei mokymuisi per dieną.

Hipotezė 5: Atmetama nulinė hipotezė. Tarp mokymosi valandų ir egzamino rezultato yra statistiškai reikšminga teigiama koreliacija ($r=0.46$). Tai reiškia, kad didėjant mokymosi valandų skaičiui, egzamino rezultatai taip pat didėja.

Hipotezė 6: Atmetama nulinė hipotezė. Studentų, besimokančių daugiau nei 5 valandas per dieną, dalis yra 40.2%, kas statistiškai reikšmingai skiriasi nuo 50%. Tai reiškia, kad dauguma studentų mokosi 5 arba mažiau valandų per dieną.

Hipotezė 7: Atmetama nulinė hipotezė. Aukšto produktyvumo pasiekimo proporcija statistiškai reikšmingai skiriasi tarp grupių. Studentų, kuriems artėja atsiskaitymas, aukšto produktyvumo proporcija yra 45.8%, o studentų, kuriems neartėja atsiskaitymas – 54.3%. Tai reiškia, kad artėjantis atsiskaitymas yra susijęs su mažesniu produktyvumu.

Bendra išvada: Tyrimas rodo, kad miego trukmė ir mokymosi valandų skaičius yra stipriausi teigiami akademiniai rezultatai veiksniai. Dauguma studentų mokosi 5 arba mažiau valandų per dieną ir vidutiniškai daugiau laiko praleidžia prie ekrano nei mokydami. Artėjantis atsiskaitymas (deadline) susijęs su mažesniu produktyvumu, o fizinis aktyvumas ir mokymosi intensyvumas reikšmingo poveikio tirtiems kintamiesiems neturėjo.